

ANÁLISE DE SÉRIES TEMPORAIS UNIVARIADAS

Trabalho para obtenção de nota no âmbito da disciplina obrigatória de “Estatística Econômica Aplicada” do curso de Mestrado Profissional em Economia – Área de Concentração em Economia – do Programa de Pós-Graduação Profissional em Economia (PPECO) da Faculdade de Ciências Econômicas (FCE) da Universidade Federal do Rio Grande do Sul (UFRGS)

Aluno: Marcus Vinicius Rossetti Guerra

Professor: Fernando Augusto Boeira Sabino da Silva

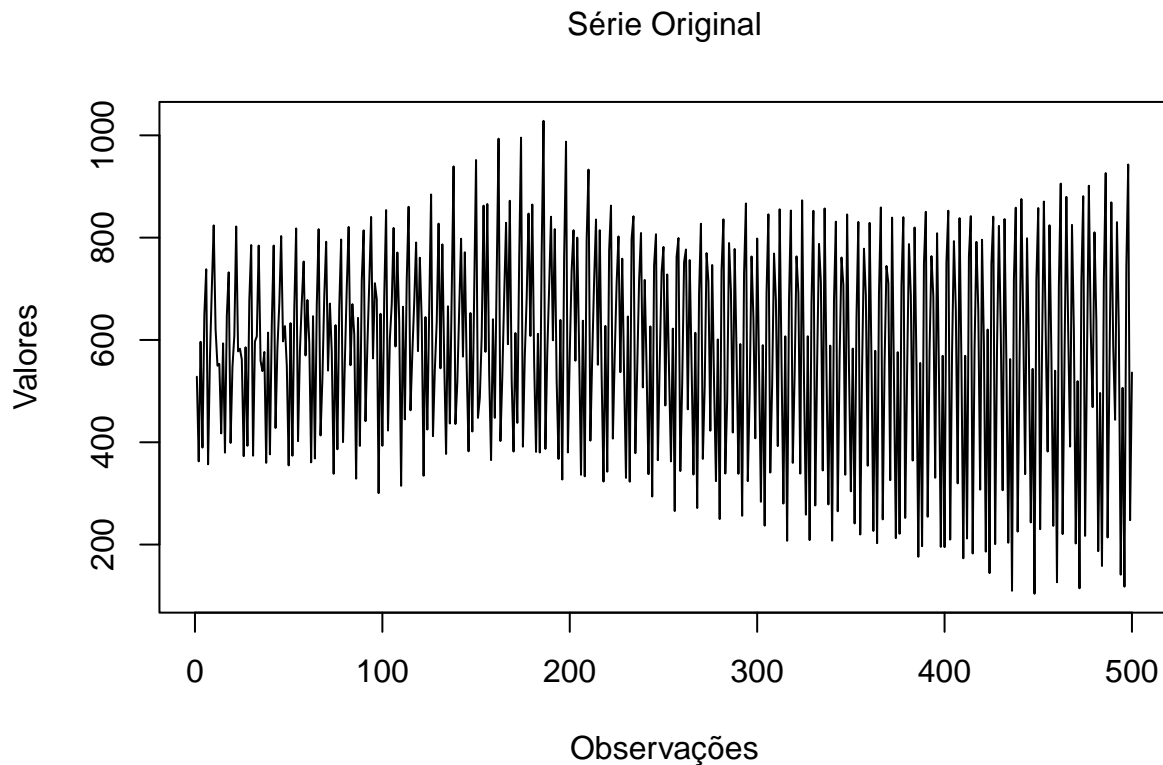
Junho/2022

1) Série Original

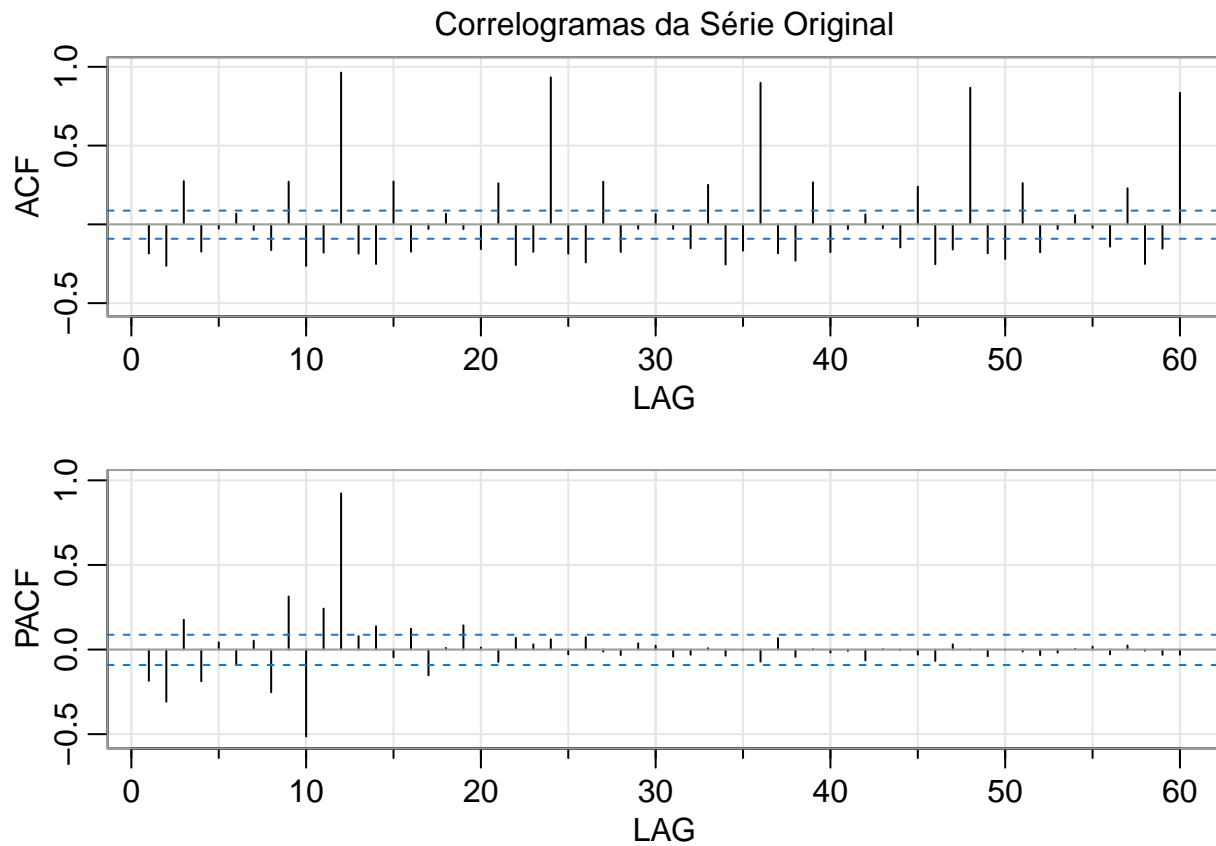
a) Arquivo com a série original

```
df <- "C:/Users/mvrgu/OneDrive/Documentos/Scanned Documents/Mestrado/Estatística Econômica Aplicada/data_MarcusGuerra.csv"
```

b) Gráfico da Série Original



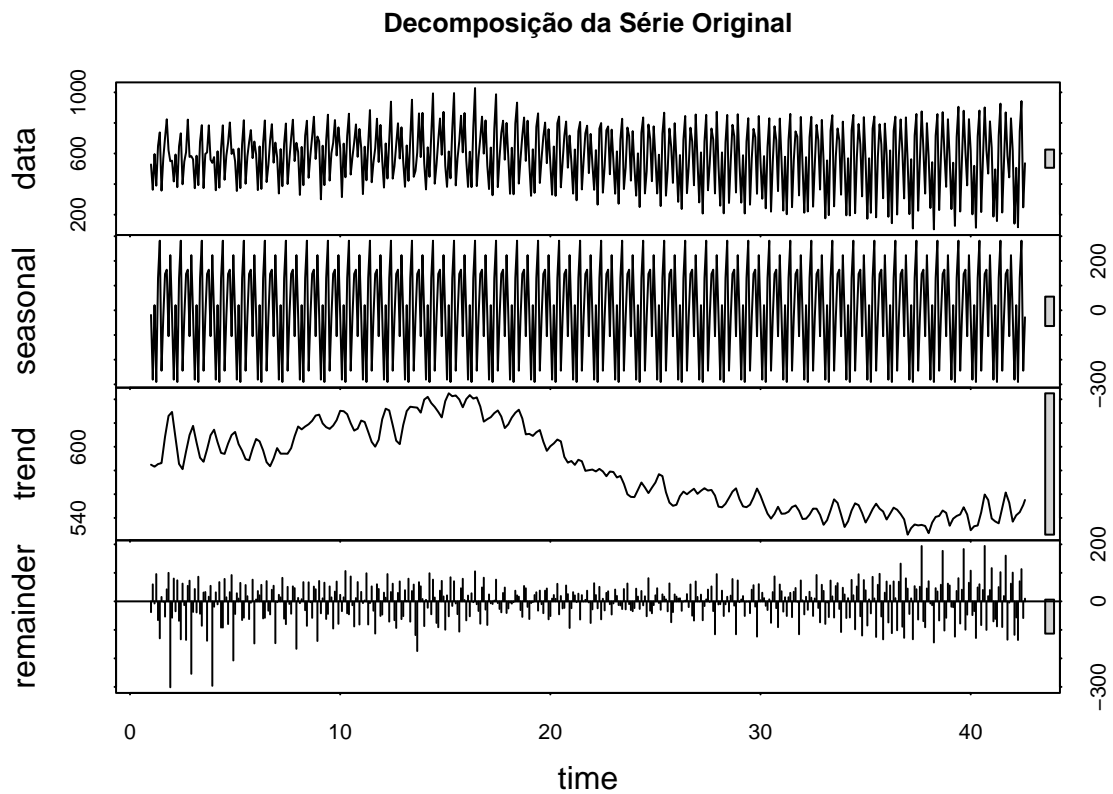
c) Correlogramas da Série Original



ANÁLISE: A ACF da Série Original sugere uma série não estacionária com sazonalidade de 12 períodos.

d) Decomposição da Série Original

```
df1 <- ts(df, frequency=12)
```




ANÁLISE: A decomposição da Série Original (com frequência de 12 períodos) sugere presença de tendência.

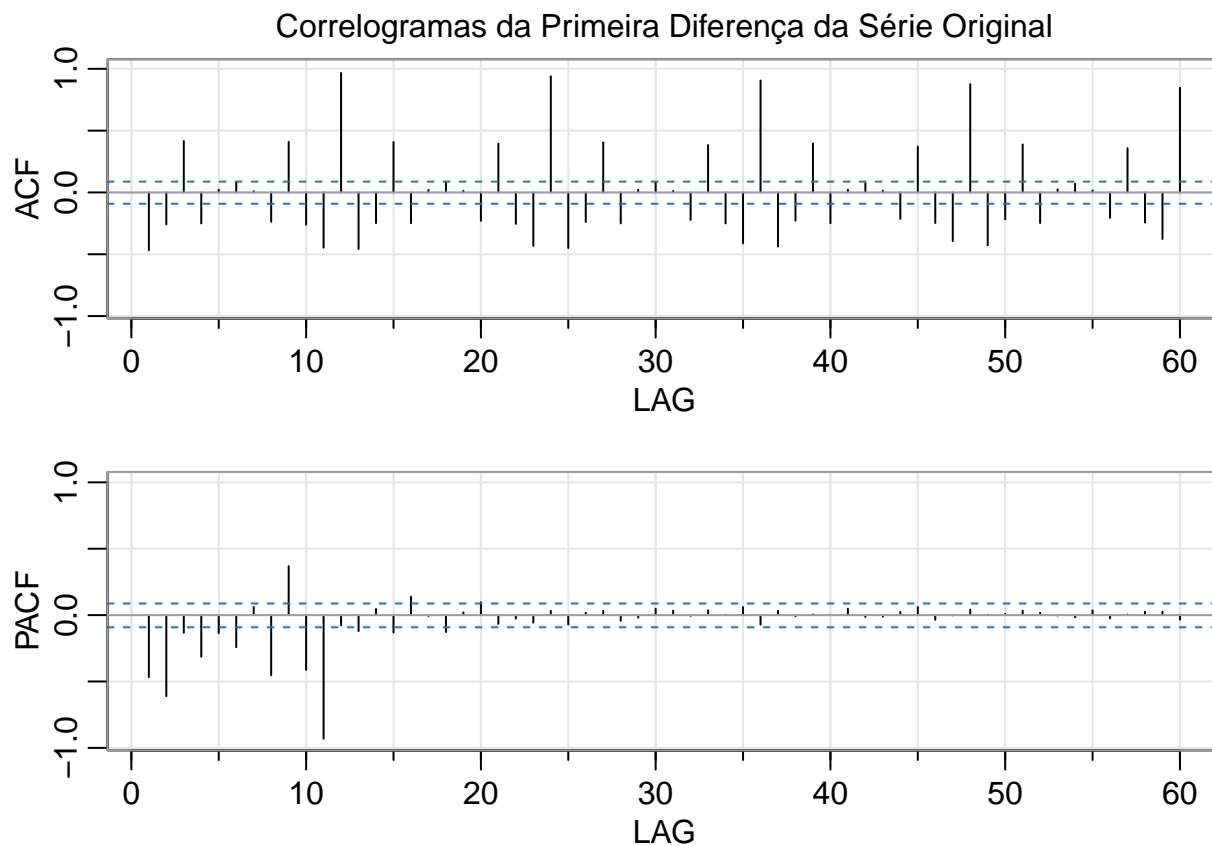
DECISÃO: Tirar a Primeira Diferença da Série Original.

2) Primeira Diferença da Série Original

a) Gráfico da Primeira Diferença da Série Original



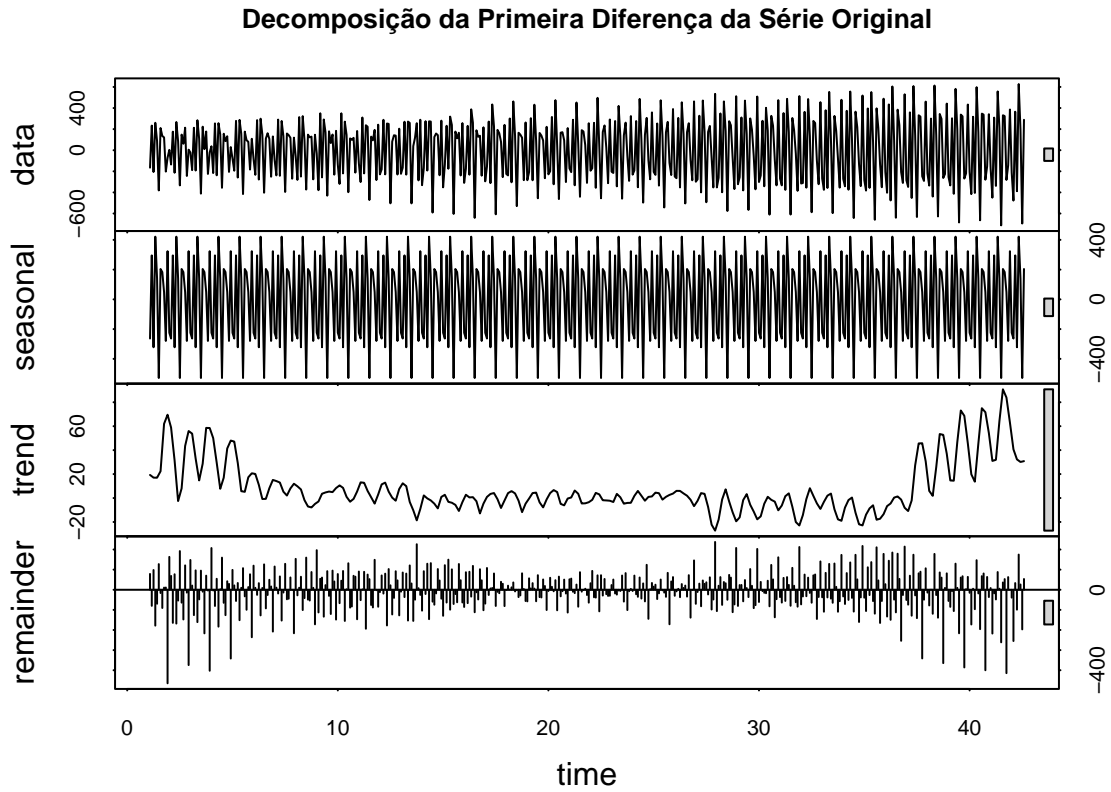
b) Correlogramas da Primeira Diferença da Série Original



ANÁLISE: A ACF da Primeira Diferença da Série Original não alterou muito a situação. Continua sugerindo uma série não estacionária com sazonalidade de 12 períodos.

c) Decomposição da Primeira Diferença da Série Original

```
df1.first_diff <- diff(df1[,2])
```




ANÁLISE: A decomposição da Primeira Diferença da Série Original (com frequência de 12 períodos) não alterou muito a situação. Continua sugerindo a presença de tendência.

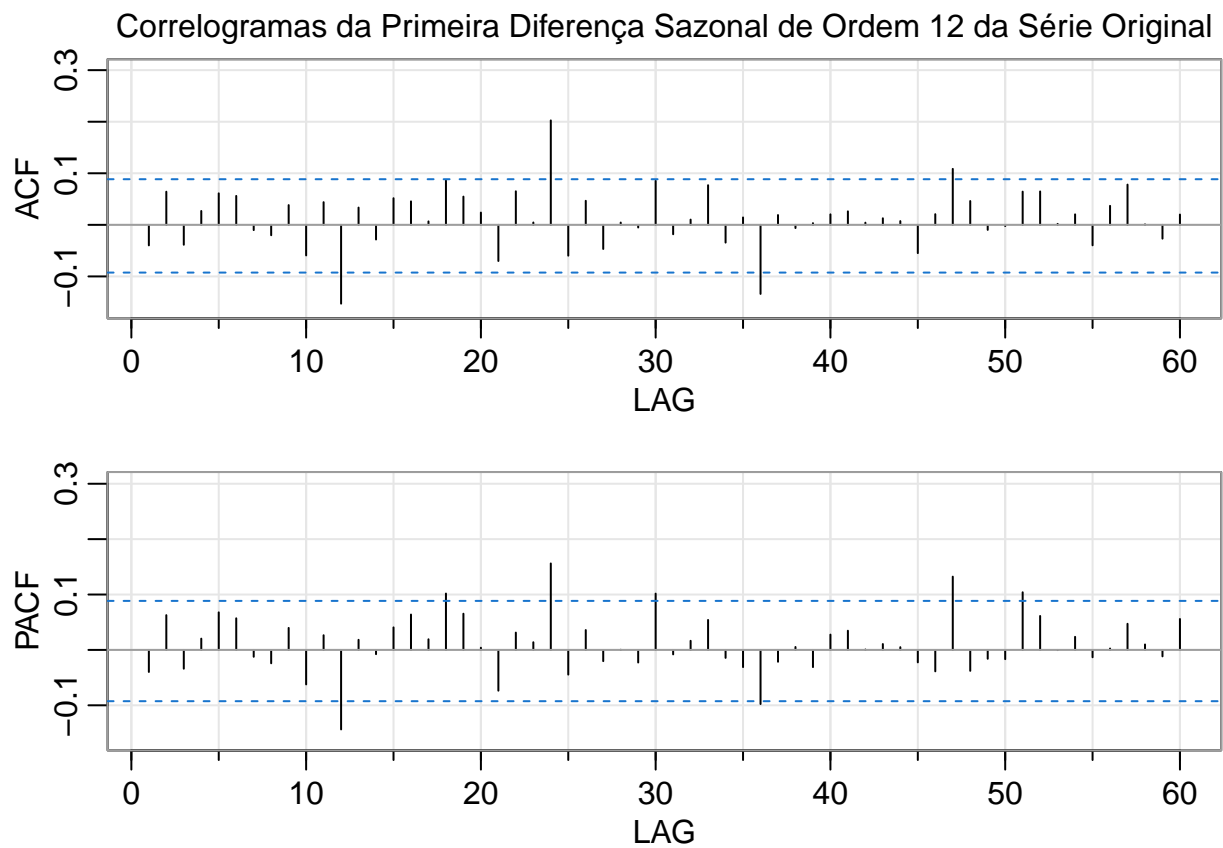
DECISÃO: Descartar a Primeira Diferença da Série Original. Tirar a Primeira Diferença Sazonal de Ordem 12 da Série Original.

3) Primeira Diferença Sazonal de Ordem 12 da Série Original

a) Gráfico da Primeira Diferença Sazonal de Ordem 12 da Série Original



b) Correlogramas da Primeira Diferença Sazonal de Ordem 12 da Série Original




ANÁLISE: A ACF da Primeira Diferença Sazonal de Ordem 12 da Série Original sugere uma série estacionária com sazonalidade de 12 períodos.

c) Decomposição da Primeira Diferença Sazonal de Ordem 12 da Série Original

```
df1.first_sdiff12 <- diff(df1[,2],12)
```


Decomposição da Primeira Diferença Sazonal de Ordem 12 da Série Original



ANÁLISE: A decomposição da Primeira Diferença Sazonal de Ordem 12 da Série Original (com frequência de 12 períodos) sugere ausência de tendência.

d) Teste ADF de raiz unitária - da Primeira Diferença Sazonal de Ordem 12 da Série Original

```
##
## #####
## # Augmented Dickey-Fuller Test Unit Root Test #
## #####
##
## Test regression drift
##
##
## Call:
## lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
##
## Residuals:
```

	Min	1Q	Median	3Q	Max
	-81.668	-20.062	-0.562	19.920	90.546

```
##
## Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.07244	1.35779	-0.790	0.4301
z.lag.1	-0.97034	0.07041	-13.780	<2e-16 ***
z.diff.lag	-0.08319	0.04847	-1.716	0.0868 .

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 28 on 424 degrees of freedom
## Multiple R-squared:  0.5325, Adjusted R-squared:  0.5303
## F-statistic: 241.5 on 2 and 424 DF,  p-value: < 2.2e-16
##
##
## Value of test-statistic is: -13.7803 94.9501
##
## Critical values for test statistics:
##      1pct  5pct 10pct
## tau2 -3.44 -2.87 -2.57
## phi1  6.47  4.61  3.79
```

ANÁLISE: O valor da estatística -13.7803 é menor que o nível crítico (tau2) -2.87 ao nível de significância de 5%. P-valor é menor que o nível de significância de 5% (0.05). Pode-se concluir pela rejeição da hipótese nula (que a série possui raiz unitária). Portanto, segundo o teste ADF, rejeita-se a hipótese que a série não é estacionária.

e) Teste KPSS de raiz unitária - da Primeira Diferença Sazonal de Ordem 12 da Série Original

```
##
## #####
## # KPSS Unit Root Test #
## #####
##
## Test is of type: mu with 5 lags.
##
## Value of test-statistic is: 0.3776
##
## Critical value for a significance level of:
##      10pct  5pct 2.5pct  1pct
## critical values 0.347 0.463  0.574 0.739
##
## KPSS Test for Level Stationarity
##
## data:  df1.first_sdiff12
## KPSS Level = 0.3776, Truncation lag parameter = 5, p-value = 0.08681
```

ANÁLISE: O valor da estatística 0.3776 é menor que o nível crítico 0.463 ao nível de significância de 5%. P-valor é maior que o nível de significância de 5% (0.05). Pode-se concluir pela não rejeição da hipótese nula (que a série não possui raiz unitária). Portanto, segundo o teste KPSS, não se rejeita a hipótese que a série é estacionária.

DECISÃO: Utilizar a Primeira Diferença Sazonal de Ordem 12 da Série Original para identificar a ordem mais ampla do modelo SARIMA.

4) Identificação da ordem mais ampla do modelo SARIMA

A FAC (da Primeira Diferença Sazonal de Ordem 12 da Série Original) sugere - conservadoramente - MA(0) para a parte regular e MA(4) para a parte sazonal ($q=0$ e $Q=4$).

A FACP (da Primeira Diferença Sazonal de Ordem 12 da Série Original) sugere - conservadoramente - AR(0) para a parte regular e AR(4) para a parte sazonal ($p=0$ e $P=4$).

Não foi aplicada a primeira diferença ($d=0$).

Foi aplicada a primeira diferença sazonal de ordem 12 ($D=1$).

DECISÃO: Sugere-se a ordem mais ampla do modelo como SARIMA(0,0,0)(4,1,4)12.

5) Identificação da ordem mais adequada do modelo SARIMA (conforme critério BIC - Bayesian Information Criterion)

a) Seleção utilizando a função `auto.arima()`

```
##
## ARIMA(0,0,0)(0,1,0)[12] : 4671.135
## ARIMA(0,0,0)(0,1,0)[12] with drift : 4677.104
## ARIMA(0,0,0)(0,1,1)[12] : 4668.646
## ARIMA(0,0,0)(0,1,1)[12] with drift : 4674.568
## ARIMA(0,0,0)(0,1,2)[12] : 4658.917
## ARIMA(0,0,0)(0,1,2)[12] with drift : 4664.924
## ARIMA(0,0,0)(0,1,3)[12] : 4652.87
## ARIMA(0,0,0)(0,1,3)[12] with drift : 4658.736
## ARIMA(0,0,0)(0,1,4)[12] : 4654.825
## ARIMA(0,0,0)(0,1,4)[12] with drift : 4660.814
## ARIMA(0,0,0)(1,1,0)[12] : 4665.31
## ARIMA(0,0,0)(1,1,0)[12] with drift : 4671.225
## ARIMA(0,0,0)(1,1,1)[12] : 4657.744
## ARIMA(0,0,0)(1,1,1)[12] with drift : 4663.667
## ARIMA(0,0,0)(1,1,2)[12] : 4653.504
## ARIMA(0,0,0)(1,1,2)[12] with drift : 4659.48
## ARIMA(0,0,0)(1,1,3)[12] : 4656.105
## ARIMA(0,0,0)(1,1,3)[12] with drift : 4662.023
## ARIMA(0,0,0)(1,1,4)[12] : 4660.996
## ARIMA(0,0,0)(1,1,4)[12] with drift : 4666.982
## ARIMA(0,0,0)(2,1,0)[12] : 4652.777
## ARIMA(0,0,0)(2,1,0)[12] with drift : 4658.789
## ARIMA(0,0,0)(2,1,1)[12] : 4656.387
## ARIMA(0,0,0)(2,1,1)[12] with drift : 4662.37
## ARIMA(0,0,0)(2,1,2)[12] : 4652.758
## ARIMA(0,0,0)(2,1,2)[12] with drift : 4658.737
## ARIMA(0,0,0)(2,1,3)[12] : Inf
## ARIMA(0,0,0)(2,1,3)[12] with drift : Inf
## ARIMA(0,0,0)(2,1,4)[12] : Inf
```

```

## ARIMA(0,0,0)(2,1,4)[12] with drift : Inf
## ARIMA(0,0,0)(3,1,0)[12] : 4654.798
## ARIMA(0,0,0)(3,1,0)[12] with drift : 4660.73
## ARIMA(0,0,0)(3,1,1)[12] : 4660.91
## ARIMA(0,0,0)(3,1,1)[12] with drift : 4666.831
## ARIMA(0,0,0)(3,1,2)[12] : Inf
## ARIMA(0,0,0)(3,1,2)[12] with drift : Inf
## ARIMA(0,0,0)(3,1,3)[12] : Inf
## ARIMA(0,0,0)(3,1,3)[12] with drift : 4670.921
## ARIMA(0,0,0)(3,1,4)[12] : Inf
## ARIMA(0,0,0)(3,1,4)[12] with drift : Inf
## ARIMA(0,0,0)(4,1,0)[12] : 4660.78
## ARIMA(0,0,0)(4,1,0)[12] with drift : 4666.689
## ARIMA(0,0,0)(4,1,1)[12] : 4662.285
## ARIMA(0,0,0)(4,1,1)[12] with drift : 4668.186
## ARIMA(0,0,0)(4,1,2)[12] : Inf
## ARIMA(0,0,0)(4,1,2)[12] with drift : Inf
## ARIMA(0,0,0)(4,1,3)[12] : Inf
## ARIMA(0,0,0)(4,1,3)[12] with drift : Inf
## ARIMA(0,0,0)(4,1,4)[12] : Inf
## ARIMA(0,0,0)(4,1,4)[12] with drift : Inf
## ARIMA(1,0,0)(0,1,0)[12] : 4676.57
## ARIMA(1,0,0)(0,1,0)[12] with drift : 4682.519
## ARIMA(1,0,0)(0,1,1)[12] : 4674.326
## ARIMA(1,0,0)(0,1,1)[12] with drift : 4680.23
## ARIMA(1,0,0)(0,1,2)[12] : 4664.768
## ARIMA(1,0,0)(0,1,2)[12] with drift : 4670.764
## ARIMA(1,0,0)(0,1,3)[12] : 4658.989
## ARIMA(1,0,0)(0,1,3)[12] with drift : 4664.847
## ARIMA(1,0,0)(0,1,4)[12] : 4660.882
## ARIMA(1,0,0)(0,1,4)[12] with drift : 4666.865
## ARIMA(1,0,0)(1,1,0)[12] : 4671.081
## ARIMA(1,0,0)(1,1,0)[12] with drift : 4676.98
## ARIMA(1,0,0)(1,1,1)[12] : 4663.504
## ARIMA(1,0,0)(1,1,1)[12] with drift : 4669.409
## ARIMA(1,0,0)(1,1,2)[12] : 4659.445
## ARIMA(1,0,0)(1,1,2)[12] with drift : 4665.411
## ARIMA(1,0,0)(1,1,3)[12] : 4662.176
## ARIMA(1,0,0)(1,1,3)[12] with drift : 4668.086
## ARIMA(1,0,0)(1,1,4)[12] : Inf
## ARIMA(1,0,0)(1,1,4)[12] with drift : 4673.028
## ARIMA(1,0,0)(2,1,0)[12] : Inf
## ARIMA(1,0,0)(2,1,0)[12] with drift : Inf
## ARIMA(1,0,0)(2,1,1)[12] : Inf
## ARIMA(1,0,0)(2,1,1)[12] with drift : Inf
## ARIMA(1,0,0)(2,1,2)[12] : Inf
## ARIMA(1,0,0)(2,1,2)[12] with drift : Inf
## ARIMA(1,0,0)(2,1,3)[12] : Inf
## ARIMA(1,0,0)(2,1,3)[12] with drift : Inf
## ARIMA(1,0,0)(2,1,4)[12] : Inf
## ARIMA(1,0,0)(2,1,4)[12] with drift : Inf
## ARIMA(1,0,0)(3,1,0)[12] : Inf
## ARIMA(1,0,0)(3,1,0)[12] with drift : Inf
## ARIMA(1,0,0)(3,1,1)[12] : Inf

```

```

## ARIMA(1,0,0)(3,1,1)[12] with drift : Inf
## ARIMA(1,0,0)(3,1,2)[12] : Inf
## ARIMA(1,0,0)(3,1,2)[12] with drift : Inf
## ARIMA(1,0,0)(3,1,3)[12] : Inf
## ARIMA(1,0,0)(3,1,3)[12] with drift : Inf
## ARIMA(1,0,0)(3,1,4)[12] : Inf
## ARIMA(1,0,0)(3,1,4)[12] with drift : Inf
## ARIMA(1,0,0)(4,1,0)[12] : Inf
## ARIMA(1,0,0)(4,1,0)[12] with drift : Inf
## ARIMA(1,0,0)(4,1,1)[12] : Inf
## ARIMA(1,0,0)(4,1,1)[12] with drift : Inf
## ARIMA(1,0,0)(4,1,2)[12] : Inf
## ARIMA(1,0,0)(4,1,2)[12] with drift : Inf
## ARIMA(1,0,0)(4,1,3)[12] : Inf
## ARIMA(1,0,0)(4,1,3)[12] with drift : Inf
## ARIMA(2,0,0)(0,1,0)[12] : 4680.783
## ARIMA(2,0,0)(0,1,0)[12] with drift : 4686.771
## ARIMA(2,0,0)(0,1,1)[12] : 4678.909
## ARIMA(2,0,0)(0,1,1)[12] with drift : 4684.854
## ARIMA(2,0,0)(0,1,2)[12] : 4670.065
## ARIMA(2,0,0)(0,1,2)[12] with drift : 4676.083
## ARIMA(2,0,0)(0,1,3)[12] : 4664.632
## ARIMA(2,0,0)(0,1,3)[12] with drift : 4670.519
## ARIMA(2,0,0)(0,1,4)[12] : 4666.616
## ARIMA(2,0,0)(0,1,4)[12] with drift : 4672.615
## ARIMA(2,0,0)(1,1,0)[12] : 4675.871
## ARIMA(2,0,0)(1,1,0)[12] with drift : 4681.809
## ARIMA(2,0,0)(1,1,1)[12] : 4668.74
## ARIMA(2,0,0)(1,1,1)[12] with drift : 4674.677
## ARIMA(2,0,0)(1,1,2)[12] : 4665.058
## ARIMA(2,0,0)(1,1,2)[12] with drift : 4671.043
## ARIMA(2,0,0)(1,1,3)[12] : 4667.868
## ARIMA(2,0,0)(1,1,3)[12] with drift : 4673.8
## ARIMA(2,0,0)(1,1,4)[12] : 4672.781
## ARIMA(2,0,0)(1,1,4)[12] with drift : 4678.776
## ARIMA(2,0,0)(2,1,0)[12] : 4664.182
## ARIMA(2,0,0)(2,1,0)[12] with drift : 4670.201
## ARIMA(2,0,0)(2,1,1)[12] : 4667.712
## ARIMA(2,0,0)(2,1,1)[12] with drift : 4673.703
## ARIMA(2,0,0)(2,1,2)[12] : 4664.791
## ARIMA(2,0,0)(2,1,2)[12] with drift : 4670.779
## ARIMA(2,0,0)(2,1,3)[12] : Inf
## ARIMA(2,0,0)(2,1,3)[12] with drift : Inf
## ARIMA(2,0,0)(2,1,4)[12] : Inf
## ARIMA(2,0,0)(2,1,4)[12] with drift : Inf
## ARIMA(2,0,0)(3,1,0)[12] : 4666.167
## ARIMA(2,0,0)(3,1,0)[12] with drift : Inf
## ARIMA(2,0,0)(3,1,1)[12] : 4672.316
## ARIMA(2,0,0)(3,1,1)[12] with drift : Inf
## ARIMA(2,0,0)(3,1,2)[12] : Inf
## ARIMA(2,0,0)(3,1,2)[12] with drift : Inf
## ARIMA(2,0,0)(3,1,3)[12] : Inf
## ARIMA(2,0,0)(3,1,3)[12] with drift : Inf
## ARIMA(2,0,0)(4,1,0)[12] : Inf

```

```

## ARIMA(2,0,0)(4,1,0)[12] with drift : Inf
## ARIMA(2,0,0)(4,1,1)[12] : Inf
## ARIMA(2,0,0)(4,1,1)[12] with drift : Inf
## ARIMA(2,0,0)(4,1,2)[12] : Inf
## ARIMA(2,0,0)(4,1,2)[12] with drift : Inf
## ARIMA(3,0,0)(0,1,0)[12] : 4686.438
## ARIMA(3,0,0)(0,1,0)[12] with drift : 4692.405
## ARIMA(3,0,0)(0,1,1)[12] : 4684.794
## ARIMA(3,0,0)(0,1,1)[12] with drift : 4690.721
## ARIMA(3,0,0)(0,1,2)[12] : 4676.191
## ARIMA(3,0,0)(0,1,2)[12] with drift : 4682.202
## ARIMA(3,0,0)(0,1,3)[12] : 4670.811
## ARIMA(3,0,0)(0,1,3)[12] with drift : 4676.694
## ARIMA(3,0,0)(0,1,4)[12] : 4672.796
## ARIMA(3,0,0)(0,1,4)[12] with drift : 4678.792
## ARIMA(3,0,0)(1,1,0)[12] : 4681.852
## ARIMA(3,0,0)(1,1,0)[12] with drift : 4687.775
## ARIMA(3,0,0)(1,1,1)[12] : 4674.877
## ARIMA(3,0,0)(1,1,1)[12] with drift : 4680.806
## ARIMA(3,0,0)(1,1,2)[12] : 4671.246
## ARIMA(3,0,0)(1,1,2)[12] with drift : 4677.229
## ARIMA(3,0,0)(1,1,3)[12] : 4674.057
## ARIMA(3,0,0)(1,1,3)[12] with drift : 4679.988
## ARIMA(3,0,0)(1,1,4)[12] : 4678.964
## ARIMA(3,0,0)(1,1,4)[12] with drift : 4684.956
## ARIMA(3,0,0)(2,1,0)[12] : Inf
## ARIMA(3,0,0)(2,1,0)[12] with drift : Inf
## ARIMA(3,0,0)(2,1,1)[12] : 4673.89
## ARIMA(3,0,0)(2,1,1)[12] with drift : Inf
## ARIMA(3,0,0)(2,1,2)[12] : Inf
## ARIMA(3,0,0)(2,1,2)[12] with drift : Inf
## ARIMA(3,0,0)(2,1,3)[12] : Inf
## ARIMA(3,0,0)(2,1,3)[12] with drift : Inf
## ARIMA(3,0,0)(3,1,0)[12] : Inf
## ARIMA(3,0,0)(3,1,0)[12] with drift : 4678.289
## ARIMA(3,0,0)(3,1,1)[12] : Inf
## ARIMA(3,0,0)(3,1,1)[12] with drift : Inf
## ARIMA(3,0,0)(3,1,2)[12] : Inf
## ARIMA(3,0,0)(3,1,2)[12] with drift : Inf
## ARIMA(3,0,0)(4,1,0)[12] : Inf
## ARIMA(3,0,0)(4,1,0)[12] with drift : Inf
## ARIMA(3,0,0)(4,1,1)[12] : Inf
## ARIMA(3,0,0)(4,1,1)[12] with drift : Inf
## ARIMA(4,0,0)(0,1,0)[12] : 4692.413
## ARIMA(4,0,0)(0,1,0)[12] with drift : 4698.393
## ARIMA(4,0,0)(0,1,1)[12] : 4690.583
## ARIMA(4,0,0)(0,1,1)[12] with drift : 4696.53
## ARIMA(4,0,0)(0,1,2)[12] : 4681.961
## ARIMA(4,0,0)(0,1,2)[12] with drift : 4687.988
## ARIMA(4,0,0)(0,1,3)[12] : 4676.209
## ARIMA(4,0,0)(0,1,3)[12] with drift : 4682.123
## ARIMA(4,0,0)(0,1,4)[12] : 4678.459
## ARIMA(4,0,0)(0,1,4)[12] with drift : 4684.471
## ARIMA(4,0,0)(1,1,0)[12] : 4687.562

```

```

## ARIMA(4,0,0)(1,1,0)[12] with drift : 4693.508
## ARIMA(4,0,0)(1,1,1)[12] : 4680.564
## ARIMA(4,0,0)(1,1,1)[12] with drift : 4686.516
## ARIMA(4,0,0)(1,1,2)[12] : 4676.938
## ARIMA(4,0,0)(1,1,2)[12] with drift : 4682.941
## ARIMA(4,0,0)(1,1,3)[12] : 4679.602
## ARIMA(4,0,0)(1,1,3)[12] with drift : 4685.558
## ARIMA(4,0,0)(2,1,0)[12] : 4676.099
## ARIMA(4,0,0)(2,1,0)[12] with drift : 4682.131
## ARIMA(4,0,0)(2,1,1)[12] : 4679.638
## ARIMA(4,0,0)(2,1,1)[12] with drift : 4685.642
## ARIMA(4,0,0)(2,1,2)[12] : 4676.452
## ARIMA(4,0,0)(2,1,2)[12] with drift : 4682.463
## ARIMA(4,0,0)(3,1,0)[12] : 4678.016
## ARIMA(4,0,0)(3,1,0)[12] with drift : 4683.977
## ARIMA(4,0,0)(3,1,1)[12] : 4684.139
## ARIMA(4,0,0)(3,1,1)[12] with drift : 4690.092
## ARIMA(4,0,0)(4,1,0)[12] : 4684.027
## ARIMA(4,0,0)(4,1,0)[12] with drift : 4689.972
## ARIMA(5,0,0)(0,1,0)[12] : 4696.31
## ARIMA(5,0,0)(0,1,0)[12] with drift : 4702.326
## ARIMA(5,0,0)(0,1,1)[12] : 4694.339
## ARIMA(5,0,0)(0,1,1)[12] with drift : 4700.33
## ARIMA(5,0,0)(0,1,2)[12] : 4686.243
## ARIMA(5,0,0)(0,1,2)[12] with drift : 4692.297
## ARIMA(5,0,0)(0,1,3)[12] : 4680.645
## ARIMA(5,0,0)(0,1,3)[12] with drift : 4686.602
## ARIMA(5,0,0)(1,1,0)[12] : 4691.326
## ARIMA(5,0,0)(1,1,0)[12] with drift : 4697.316
## ARIMA(5,0,0)(1,1,1)[12] : 4684.501
## ARIMA(5,0,0)(1,1,1)[12] with drift : 4690.496
## ARIMA(5,0,0)(1,1,2)[12] : 4681.419
## ARIMA(5,0,0)(1,1,2)[12] with drift : 4687.452
## ARIMA(5,0,0)(2,1,0)[12] : 4680.463
## ARIMA(5,0,0)(2,1,0)[12] with drift : 4686.521
## ARIMA(5,0,0)(2,1,1)[12] : 4683.974
## ARIMA(5,0,0)(2,1,1)[12] with drift : 4690.009
## ARIMA(5,0,0)(3,1,0)[12] : 4682.324
## ARIMA(5,0,0)(3,1,0)[12] with drift : 4688.322
##
##
## Best model: ARIMA(0,0,0)(2,1,2)[12]


## Series: df1[, 2]
## ARIMA(0,0,0)(2,1,2)[12]
##
## Coefficients:
##          sar1      sar2      sma1      sma2
##      -1.0379  -0.5964   0.9604   0.7453
## s.e.   0.1320   0.2436   0.1473   0.2422
##
## sigma^2 = 758.6: log likelihood = -2310.9
## AIC=4631.81 AICc=4631.93 BIC=4652.76

```

```
##
## Training set error measures:
##           ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.4967398 27.09892 21.30265 -0.6167354 4.517849 0.9271633
##           ACF1
## Training set -0.007432159
```

ANÁLISE: O menor BIC (4652.76) é o SARIMA(0,0,0)(2,1,2)₁₂.

b) Verificação das condições de estacionariedade e invertibilidade




ANÁLISE: No caso do SARIMA(0,0,0)(2,1,2)₁₂, as raízes inversas das equações características dos polinômios (autorregressivo sazonal e de médias móveis sazonal) estão dentro dos círculos unitários. Logo, as condições de estacionariedade e invertibilidade estão satisfeitas.

DECISÃO: Sugere-se a ordem mais adequada do modelo como SARIMA(0,0,0)(2,1,2)₁₂.


6) Avaliação dos resíduos da ordem (selecionada) mais adequada do modelo SARIMA

a) Correlogramas dos resíduos da ordem (selecionada) mais adequada do modelo SARIMA



ANÁLISE: Quase todas as autocorrelações dos resíduos - da ordem (selecionada) mais adequada do modelo SARIMA - estão dentro dos limites, ou seja, indicando que os resíduos se comportam como um ruído branco.

b) Teste Ljung-Box de distribuição independente dos resíduos da ordem (selecionada) mais adequada do modelo SARIMA



```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(0,0,0)(2,1,2)[12]
## Q* = 18.475, df = 20, p-value = 0.5561
##
## Model df: 4.    Total lags used: 24
```

ANÁLISE: P-valor é maior que o nível de significância de 5% (0.05). Pode-se concluir pela não rejeição da hipótese nula (que os resíduos são independentemente distribuídos). Portanto, segundo o teste Ljung-Box, não se rejeita a hipótese que os resíduos se comportam como um ruído branco.

c) Teste Jarque-Bera de distribuição normal dos resíduos da ordem (selecionada) mais adequada do modelo SARIMA

```
##
##  Jarque Bera Test
##
## data:  residuals(fit13)
## X-squared = 2.3968, df = 2, p-value = 0.3017
```

ANÁLISE: P-valor é maior que o nível de significância de 5% (0.05). Pode-se concluir pela não rejeição da hipótese nula (que os resíduos são normalmente distribuídos). Portanto, segundo o teste Jarque-Bera, não se

rejeita a hipótese que os resíduos se comportam como um ruído branco.

DECISÃO: O exame dos resíduos - da ordem (selecionada) mais adequada do modelo SARIMA - indica que os resíduos se comportam como um ruído branco.

7) Seleção do melhor modelo de previsão

a) Divisão da Série Original em Série de Treinamento e Série de Teste

df_train <- Série de Treinamento com 476 observações

df_test <- Série de Teste com 24 observações (frequência = 12 x maior AR/MA da ordem selecionada mais adequada do modelo SARIMA = 2)

b) Critérios para avaliação do melhor modelo de previsão

Menor BIC (Bayesian Information Criterion) ou “Critério de Informação Bayesiano”.



Menor RMSE (Root Mean Squared Error) ou “Raiz Quadrada do Erro Médio”.

Menor MAPE (Mean Absolute Percentage Error) ou “Média Percentual Absoluta do Erro”.


Menor Theil's U ou “U de Theil”.

c) Modelo 1 = SARIMA(0,0,0)(2,1,2)12 - ordem (selecionada) mais adequada do modelo SARIMA

```
## Series: df_train
## ARIMA(0,0,0)(2,1,2)[12]
##
## Coefficients:
##          sar1      sar2      sma1      sma2
##          -1.0238  -0.5196  0.9543  0.6762
## s.e.      0.1088   0.1757  0.0989  0.1933
##
## sigma^2 = 753.7: log likelihood = -2195.28
## AIC=4400.56   AICc=4400.7   BIC=4421.26
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.7315152 26.98768 21.12081 -0.6317913 4.360334 0.9243443
##              ACF1
## Training set -0.0152645
## [1] 4421.264
##
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.7315152 26.98768 21.12081 -0.6317913 4.360334 0.9243443
## Test set      9.8669698 31.83132 25.31877  1.6809279 7.054786 1.1080660
##              ACF1 Theil's U
## Training set -0.01526450      NA
## Test set      -0.02269539 0.05631508
```



Residuals from ARIMA(0,0,0)(2,1,2)[12]



```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(0,0,0)(2,1,2)[12]
## Q* = 16.721, df = 20, p-value = 0.671
##
## Model df: 4.   Total lags used: 24
##
##  Jarque Bera Test
##
## data:  residuals(m1)
## X-squared = 3.6183, df = 2, p-value = 0.1638
```

ANÁLISE:

Quase todas as autocorrelações dos resíduos estão dentro dos limites - indicando que os resíduos se comportam como um ruído branco.



P-valor do teste Ljung-Box é maior que o nível de significância de 5% (0.05). Pode-se concluir pela não rejeição da hipótese nula (que os resíduos são independentemente distribuídos). Portanto, segundo o teste Ljung-Box, não se rejeita a hipótese que os resíduos se comportam como um ruído branco.

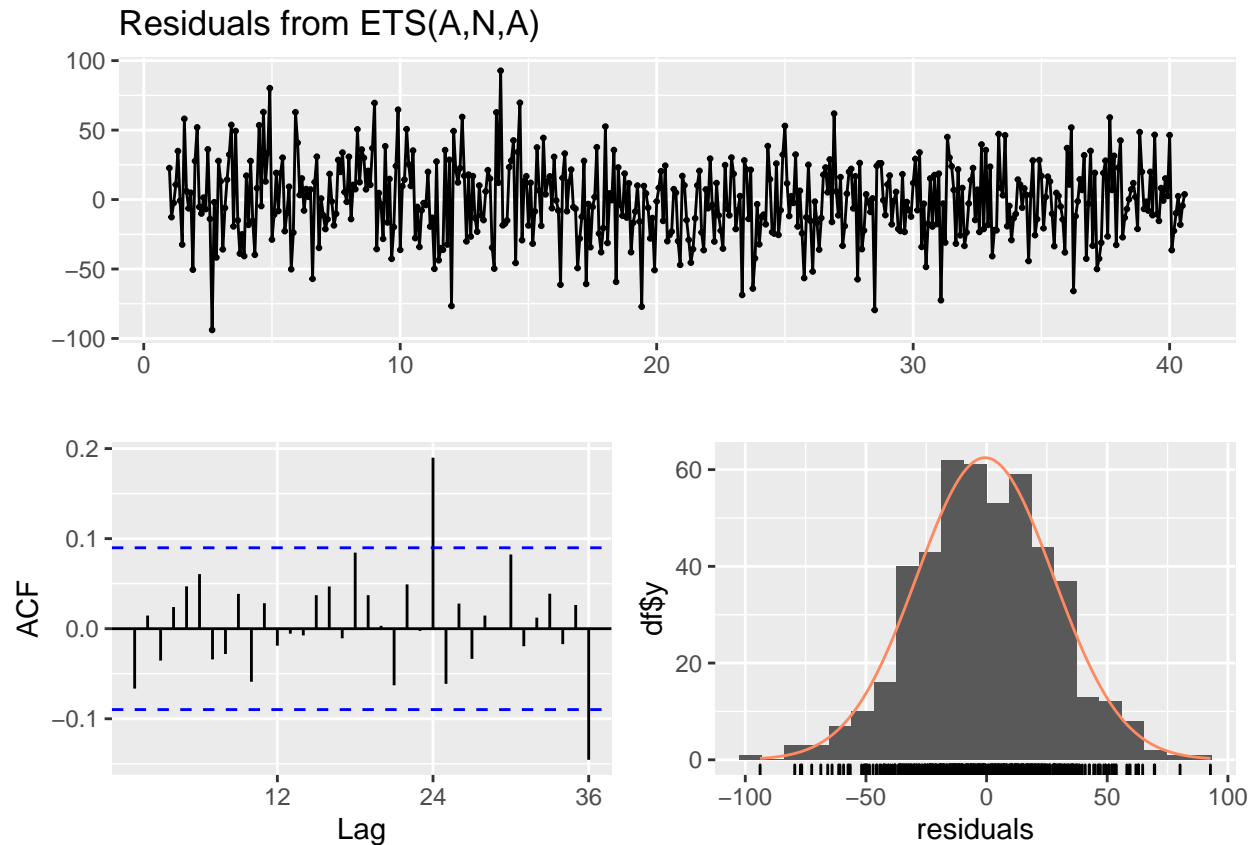
P-valor do teste Jarque-Bera é maior que o nível de significância de 5% (0.05). Pode-se concluir pela não rejeição da hipótese nula (que os resíduos são normalmente distribuídos). Portanto, segundo o teste

Jarque-Bera, não se rejeita a hipótese que os resíduos se comportam como um ruído branco.

d) Modelo 2 = ETS (suavização exponencial com tendência e sazonalidade)

```
## ETS(A,N,A)
##
## Call:
## ets(y = df_train)
##
## Smoothing parameters:
##   alpha = 0.019
##   gamma = 0.8512
##
## Initial states:
##   l = 570.4124
##   s = 28.191 44.424 258.3683 124.4029 -61.3968 -181.9911
##       167.6063 44.1037 -191.6796 28.3412 -195.4453 -64.9246
##
## sigma: 28.7716
##
##      AIC      AICc      BIC
## 6148.668 6149.712 6211.150
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.6084642 28.34537 22.63717 -0.7182895 4.6632 0.9907068
##              ACF1
## Training set -0.06653322
##
## [1] 6211.15
##
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.6084642 28.34537 22.63717 -0.7182895 4.663200 0.9907068
## Test set      8.5245490 33.80884 26.85535  0.6668278 7.418479 1.1753138
##              ACF1  Theil's U
## Training set -0.066533218      NA
## Test set      -0.001158543 0.05650729
```





```
##
##  Ljung-Box test
##
## data:  Residuals from ETS(A,N,A)
## Q* = 37.33, df = 10, p-value = 4.963e-05
##
## Model df: 14.    Total lags used: 24
```

ANÁLISE:

As autocorrelações dos resíduos mostram decaimento exponencial sazonal - indicando que os resíduos não se comportam como um ruído branco.

P-valor do teste Ljung-Box é menor que o nível de significância de 5% (0.05). Pode-se concluir pela rejeição da hipótese nula (que os resíduos são independentemente distribuídos). Portanto, segundo o teste Ljung-Box, rejeita-se a hipótese que os resíduos se comportam como um ruído branco.

e) Modelo 3 = TSLM (linear com tendência e sazonalidade)



```
##
## Call:
## tslm(formula = df_train ~ season + trend)
##
## Residuals:
```




```

##      Min      1Q   Median      3Q      Max
## -266.116 -43.071    4.852   46.924  185.631
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  599.85764   12.05629   49.755 < 2e-16 ***
## season2     -254.42739   15.27560  -16.656 < 2e-16 ***
## season3       47.04735   15.27565    3.080 0.00219 **
## season4     -264.41609   15.27573  -17.310 < 2e-16 ***
## season5      150.67532   15.27585    9.864 < 2e-16 ***
## season6      298.88767   15.27601   19.566 < 2e-16 ***
## season7     -220.16190   15.27619  -14.412 < 2e-16 ***
## season8       -6.59305   15.27641   -0.432 0.66624
## season9      171.51447   15.37326   11.157 < 2e-16 ***
## season10     190.15886   15.37334   12.369 < 2e-16 ***
## season11     -88.23499   15.37346   -5.739 1.72e-08 ***
## season12     211.32059   15.37361   13.746 < 2e-16 ***
## trend        -0.16603    0.02279   -7.286 1.39e-12 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 68.31 on 463 degrees of freedom
## Multiple R-squared:  0.8846, Adjusted R-squared:  0.8817
## F-statistic: 295.9 on 12 and 463 DF,  p-value: < 2.2e-16
## [1] 5445.328
##
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -2.947011e-15  67.37515  53.28216  -2.928651  11.87971  2.331873
## Test set     1.448295e+01 100.97765  89.97827 -10.870601  24.54486  3.937864
##
##              ACF1 Theil's U
## Training set -0.07173188    NA
## Test set     -0.13052501  0.1503092

```



Residuals from Linear regression model



```
##
##  Ljung-Box test
##
## data:  Residuals from Linear regression model
## Q* = 1001.9, df = 11, p-value < 2.2e-16
##
## Model df: 13.   Total lags used: 24
```

ANÁLISE:

As autocorrelações dos resíduos mostram decaimento exponencial sazonal - indicando que os resíduos não se comportam como um ruído branco.

P-valor do teste Ljung-Box é menor que o nível de significância de 5% (0.05). Pode-se concluir pela rejeição da hipótese nula (que os resíduos são independentemente distribuídos). Portanto, segundo o teste Ljung-Box, rejeita-se a hipótese que os resíduos se comportam como um ruído branco.



f) Modelo 4 = Holt-Winters (suavização exponencial tripla)

```
##
## Forecast method: Holt's method
##
## Model Information:
## Holt's method
```

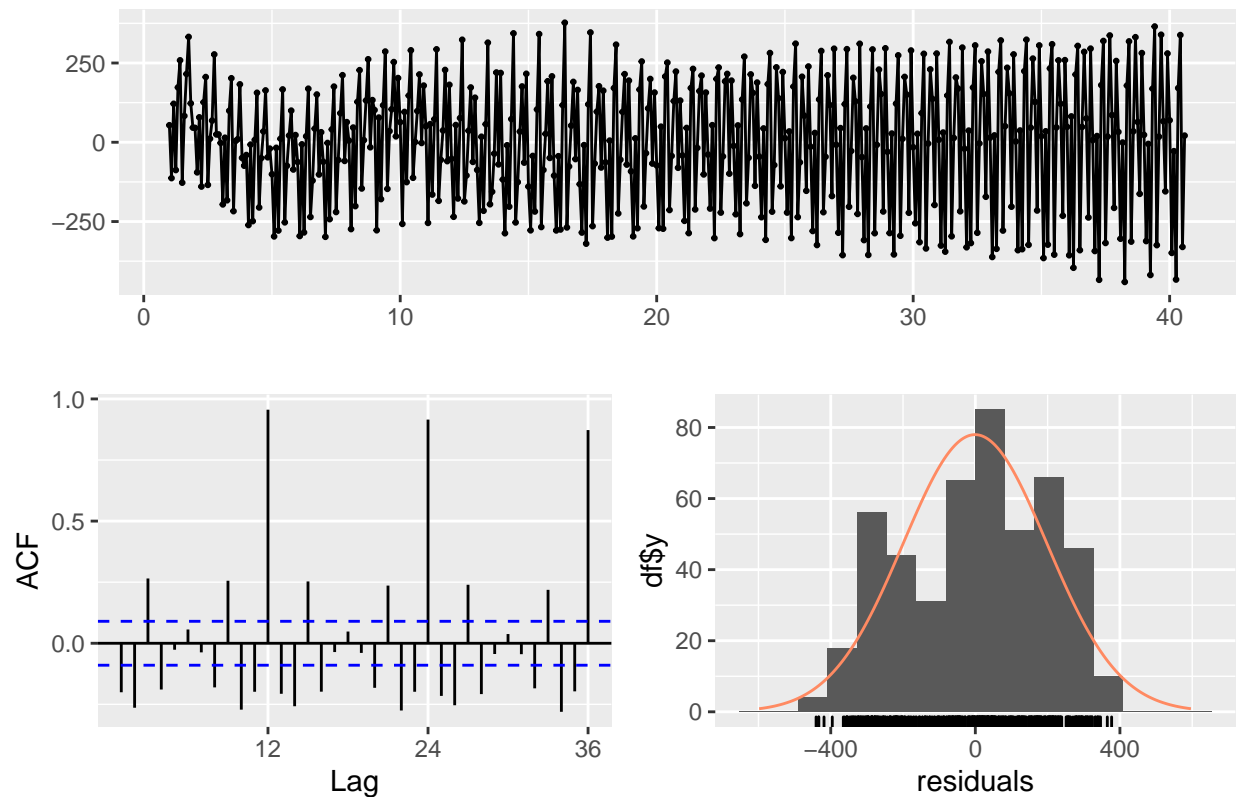
```

##
## Call:
## holt(y = df_train, h = 24)
##
## Smoothing parameters:
##   alpha = 0.0109
##   beta  = 0.0029
##
## Initial states:
##   l = 473.8364
##   b = 0.6308
##
## sigma: 199.718
##
##      AIC      AICc      BIC
## 7983.377 7983.505 8004.204
##
## Error measures:
##
##           ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set -0.8074659 198.8771 165.9093 -18.9814 40.1806 7.260956 -0.200587
##
## Forecasts:
##      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
## Sep 40      542.6381 286.6891 798.5871 151.1979 934.0783
## Oct 40      542.1565 286.1831 798.1300 150.6789 933.6341
## Nov 40      541.6750 285.6657 797.6842 150.1426 933.2073
## Dec 40      541.1934 285.1349 797.2519 149.5857 932.8011
## Jan 41      540.7118 284.5884 796.8352 149.0049 932.4187
## Feb 41      540.2302 284.0243 796.4361 148.3971 932.0634
## Mar 41      539.7486 283.4403 796.0570 147.7589 931.7384
## Apr 41      539.2671 282.8344 795.6998 147.0871 931.4470
## May 41      538.7855 282.2044 795.3666 146.3786 931.1924
## Jun 41      538.3039 281.5482 795.0596 145.6300 930.9779
## Jul 41      537.8223 280.8638 794.7809 144.8382 930.8065
## Aug 41      537.3408 280.1491 794.5324 144.0001 930.6814
## Sep 41      536.8592 279.4021 794.3163 143.1125 930.6059
## Oct 41      536.3776 278.6206 794.1346 142.1723 930.5829
## Nov 41      535.8960 277.8028 793.9893 141.1765 930.6156
## Dec 41      535.4145 276.9466 793.8824 140.1219 930.7070
## Jan 42      534.9329 276.0500 793.8158 139.0057 930.8601
## Feb 42      534.4513 275.1112 793.7914 137.8249 931.0778
## Mar 42      533.9697 274.1283 793.8112 136.5765 931.3629
## Apr 42      533.4882 273.0994 793.8770 135.2579 931.7185
## May 42      533.0066 272.0227 793.9905 133.8661 932.1471
## Jun 42      532.5250 270.8964 794.1537 132.3985 932.6515
## Jul 42      532.0434 269.7188 794.3681 130.8525 933.2344
## Aug 42      531.5619 268.4882 794.6355 129.2254 933.8983
##
##           ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set -0.8074659 198.8771 165.9093 -18.9814 40.1806 7.260956 -0.200587
## Test set     15.7800796 259.7286 214.7473 -43.35139 71.5085 9.398333 -0.1352021
##
## Theil's U
## Training set      NA
## Test set         0.3800267

```



Residuals from Holt's method



```
##
##  Ljung-Box test
##
## data:  Residuals from Holt's method
## Q* = 1288.7, df = 20, p-value < 2.2e-16
##
## Model df: 4.   Total lags used: 24
```

ANÁLISE:

As autocorrelações dos resíduos mostram decaimento exponencial sazonal - indicando que os resíduos não se comportam como um ruído branco.

P-valor do teste Ljung-Box é menor que o nível de significância de 5% (0.05). Pode-se concluir pela rejeição da hipótese nula (que os resíduos são independentemente distribuídos). Portanto, segundo o teste Ljung-Box, rejeita-se a hipótese que os resíduos se comportam como um ruído branco.

g) Modelo 5 = Holt-Winters + damped (suavização exponencial tripla - amortecida)



```
##
## Forecast method: Damped Holt's method
##
## Model Information:
## Damped Holt's method
```

```

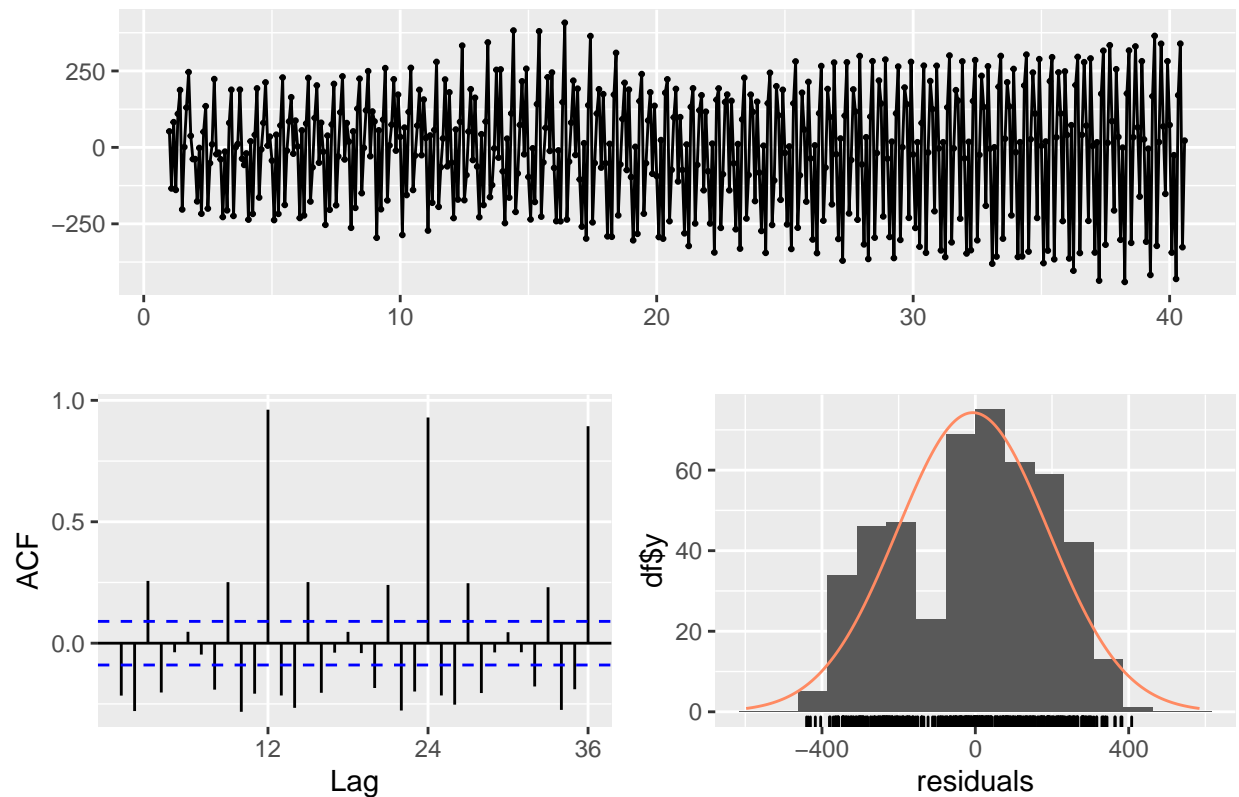
##
## Call:
## holt(y = df_train, h = 24, damped = TRUE)
##
## Smoothing parameters:
##   alpha = 0.0033
##   beta  = 0.0033
##   phi   = 0.8338
##
## Initial states:
##   l = 450.6698
##   b = 30.1487
##
## sigma: 198.0355
##
##      AIC      AICc      BIC
## 7976.313 7976.492 8001.306
##
## Error measures:
##
##           ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set -6.582369 196.9927 162.4914 -20.29237 40.11021 7.111374 -0.2157943
##
## Forecasts:
##      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
## Sep 40      541.4296 287.6369 795.2223 153.2872 929.5721
## Oct 40      541.0834 287.2860 794.8808 152.9338 929.2331
## Nov 40      540.7947 286.9884 794.6011 152.6314 928.9581
## Dec 40      540.5540 286.7341 794.3739 152.3700 928.7380
## Jan 41      540.3533 286.5153 794.1912 152.1417 928.5649
## Feb 41      540.1859 286.3257 794.0462 151.9401 928.4317
## Mar 41      540.0464 286.1599 793.9329 151.7605 928.3323
## Apr 41      539.9300 286.0137 793.8462 151.5986 928.2614
## May 41      539.8330 285.8839 793.7820 151.4514 928.2146
## Jun 41      539.7521 285.7675 793.7367 151.3161 928.1880
## Jul 41      539.6846 285.6622 793.7070 151.1908 928.1784
## Aug 41      539.6283 285.5661 793.6906 151.0736 928.1831
## Sep 41      539.5814 285.4776 793.6852 150.9632 928.1997
## Oct 41      539.5423 285.3956 793.6891 150.8584 928.2263
## Nov 41      539.5097 285.3188 793.7007 150.7582 928.2612
## Dec 41      539.4825 285.2464 793.7187 150.6619 928.3032
## Jan 42      539.4599 285.1776 793.7421 150.5687 928.3510
## Feb 42      539.4409 285.1119 793.7700 150.4782 928.4037
## Mar 42      539.4252 285.0487 793.8016 150.3900 928.4604
## Apr 42      539.4120 284.9877 793.8364 150.3035 928.5205
## May 42      539.4011 284.9284 793.8738 150.2186 928.5835
## Jun 42      539.3919 284.8705 793.9133 150.1350 928.6488
## Jul 42      539.3843 284.8139 793.9547 150.0525 928.7161
## Aug 42      539.3780 284.7583 793.9976 149.9708 928.7851
##
##           ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set -6.582369 196.9927 162.4914 -20.29237 40.11021 7.111374 -0.2157943
## Test set     13.018205 259.9010 214.6784 -44.18298 71.93835 9.395317 -0.1332739
##           Theil's U
## Training set      NA

```

Test set 0.375986



Residuals from Damped Holt's method



```
##
##  Ljung-Box test
##
## data:  Residuals from Damped Holt's method
## Q* = 1327.2, df = 19, p-value < 2.2e-16
##
## Model df: 5.   Total lags used: 24
```

ANÁLISE:

As autocorrelações dos resíduos mostram decaimento exponencial sazonal - indicando que os resíduos não se comportam como um ruído branco.

P-valor do teste Ljung-Box é menor que o nível de significância de 5% (0.05). Pode-se concluir pela rejeição da hipótese nula (que os resíduos são independentemente distribuídos). Portanto, segundo o teste Ljung-Box, rejeita-se a hipótese que os resíduos se comportam como um ruído branco.



h) Modelo 6 = SES (suavização exponencial simples)

```
##
## Forecast method: Simple exponential smoothing
##
## Model Information:
## Simple exponential smoothing
##
```

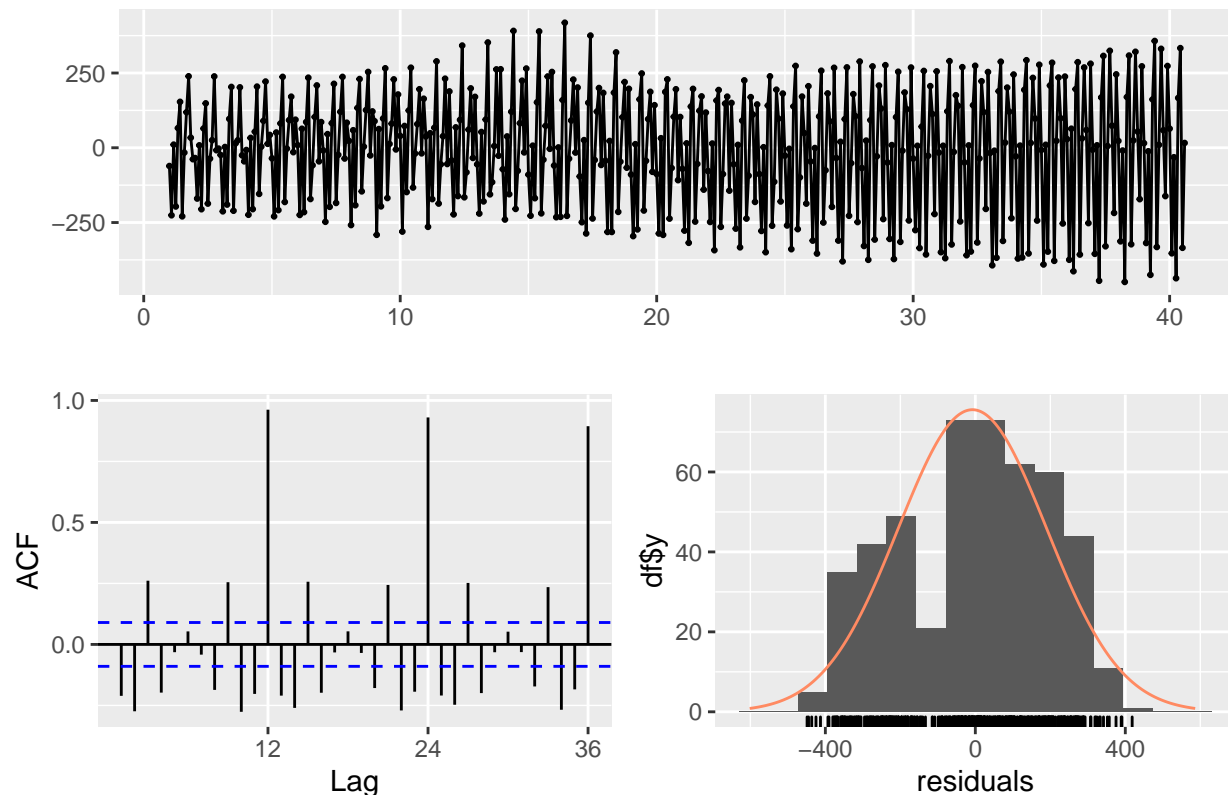
```

## Call:
## ses(y = df_train, h = 24)
##
## Smoothing parameters:
##   alpha = 0.0112
##
## Initial states:
##   l = 589.1603
##
## sigma: 198.3884
##
##      AIC      AICc      BIC
## 7975.031 7975.081 7987.527
##
## Error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set -7.730799 197.9712 162.719 -20.80896 40.46585 7.121336 -0.2108126
##
## Forecasts:
##      Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
## Sep 40      548.0186 293.7736 802.2636 159.1844 936.8527
## Oct 40      548.0186 293.7577 802.2795 159.1601 936.8770
## Nov 40      548.0186 293.7418 802.2954 159.1358 936.9013
## Dec 40      548.0186 293.7259 802.3112 159.1115 936.9256
## Jan 41      548.0186 293.7101 802.3271 159.0873 936.9499
## Feb 41      548.0186 293.6942 802.3430 159.0630 936.9742
## Mar 41      548.0186 293.6783 802.3589 159.0387 936.9985
## Apr 41      548.0186 293.6624 802.3748 159.0144 937.0228
## May 41      548.0186 293.6465 802.3907 158.9901 937.0471
## Jun 41      548.0186 293.6306 802.4066 158.9658 937.0714
## Jul 41      548.0186 293.6148 802.4224 158.9415 937.0957
## Aug 41      548.0186 293.5989 802.4383 158.9172 937.1200
## Sep 41      548.0186 293.5830 802.4542 158.8929 937.1443
## Oct 41      548.0186 293.5671 802.4701 158.8687 937.1685
## Nov 41      548.0186 293.5512 802.4859 158.8444 937.1928
## Dec 41      548.0186 293.5354 802.5018 158.8201 937.2171
## Jan 42      548.0186 293.5195 802.5177 158.7958 937.2414
## Feb 42      548.0186 293.5036 802.5336 158.7715 937.2657
## Mar 42      548.0186 293.4878 802.5494 158.7473 937.2899
## Apr 42      548.0186 293.4719 802.5653 158.7230 937.3142
## May 42      548.0186 293.4560 802.5812 158.6987 937.3385
## Jun 42      548.0186 293.4401 802.5971 158.6744 937.3627
## Jul 42      548.0186 293.4243 802.6129 158.6502 937.3870
## Aug 42      548.0186 293.4084 802.6288 158.6259 937.4113
##
##              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set -7.730799 197.9712 162.7190 -20.80896 40.46585 7.121336 -0.2108126
## Test set      4.861467 259.7337 214.3377 -46.38656 72.98095 9.380409 -0.1327014
##              Theil's U
## Training set      NA
## Test set      0.3693487

```



Residuals from Simple exponential smoothing



```
##
##  Ljung-Box test
##
## data:  Residuals from Simple exponential smoothing
## Q* = 1317.9, df = 22, p-value < 2.2e-16
##
## Model df: 2.   Total lags used: 24
```

ANÁLISE:

As autocorrelações dos resíduos mostram decaimento exponencial sazonal - indicando que os resíduos não se comportam como um ruído branco.

P-valor do teste Ljung-Box é menor que o nível de significância de 5% (0.05). Pode-se concluir pela rejeição da hipótese nula (que os resíduos são independentemente distribuídos). Portanto, segundo o teste Ljung-Box, rejeita-se a hipótese que os resíduos se comportam como um ruído branco.



i) Modelo 7 = NAIVE (modelo “ingênuo” / passeio aleatório com tendência)

```
##
## Forecast method: Naive method
##
## Model Information:
## Call: naive(y = df_train, h = 24)
##
```

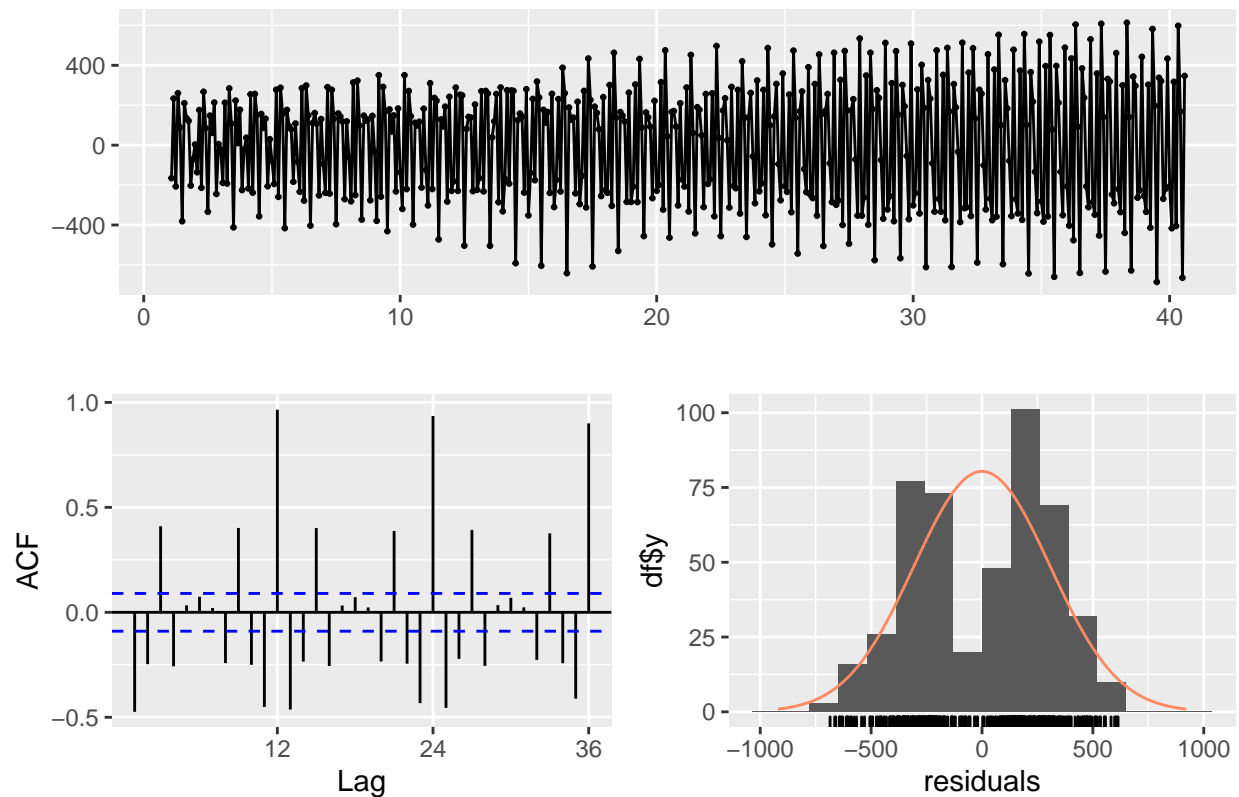
```

## Residual sd: 306.432
##
## Error measures:
##           ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
## Training set 0.0751786 306.432 272.5321 -23.64112 62.66369 11.92726 -0.4739422
##
## Forecasts:
##           Point Forecast      Lo 80      Hi 80      Lo 95      Hi 95
## Sep 40      563.8623    171.153864  956.5707   -36.73341 1164.458
## Oct 40      563.8623      8.488715 1119.2358  -285.50829 1413.233
## Nov 40      563.8623   -116.328644 1244.0532  -476.39997 1604.125
## Dec 40      563.8623   -221.554545 1349.2791  -637.32909 1765.054
## Jan 41      563.8623   -314.260425 1441.9850  -779.11050 1906.835
## Feb 41      563.8623   -398.072947 1525.7975  -907.29069 2035.015
## Mar 41      563.8623   -475.146515 1602.8711 -1025.16454 2152.889
## Apr 41      563.8623   -546.884843 1674.6094 -1134.87885 2262.603
## May 41      563.8623   -614.262954 1741.9875 -1237.92478 2365.649
## Jun 41      563.8623   -677.990756 1805.7153 -1335.38804 2463.113
## Jul 41      563.8623   -738.604172 1866.3287 -1428.08826 2555.813
## Aug 41      563.8623   -796.519561 1924.2441 -1516.66220 2644.387
## Sep 41      563.8623   -852.068032 1979.7926 -1601.61626 2729.341
## Oct 41      563.8623   -905.518046 2033.2426 -1683.36100 2811.086
## Nov 41      563.8623   -957.090855 2084.8154 -1762.23481 2889.959
## Dec 41      563.8623  -1006.971363 2134.6959 -1838.52046 2966.245
## Jan 42      563.8623  -1055.315977 2183.0405 -1912.45717 3040.182
## Feb 42      563.8623  -1102.258401 2229.9829 -1984.24941 3111.974
## Mar 42      563.8623  -1147.913996 2275.6385 -2054.07362 3181.798
## Apr 42      563.8623  -1192.383123 2320.1077 -2122.08328 3249.808
## May 42      563.8623  -1235.753737 2363.4783 -2188.41291 3316.137
## Jun 42      563.8623  -1278.103437 2405.8280 -2253.18118 3380.906
## Jul 42      563.8623  -1319.501094 2447.2256 -2316.49344 3444.218
## Aug 42      563.8623  -1360.008166 2487.7327 -2378.44366 3506.168
##
##           ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.0751786 306.4320 272.5321 -23.64112 62.66369 11.927263
## Test set    -10.9822078 259.9203 214.3377 -50.61871 75.09089  9.380409
##           ACF1 Theil's U
## Training set -0.4739422      NA
## Test set    -0.1327014  0.359072

```



Residuals from Naive method



```
##
##  Ljung-Box test
##
## data:  Residuals from Naive method
## Q* = 1857.6, df = 24, p-value < 2.2e-16
##
## Model df: 0.   Total lags used: 24
```

ANÁLISE:

As autocorrelações dos resíduos mostram decaimento exponencial sazonal - indicando que os resíduos não se comportam como um ruído branco.

P-valor do teste Ljung-Box é menor que o nível de significância de 5% (0.05). Pode-se concluir pela rejeição da hipótese nula (que os resíduos são independentemente distribuídos). Portanto, segundo o teste Ljung-Box, rejeita-se a hipótese que os resíduos se comportam como um ruído branco.

j) Resultado da avaliação do melhor modelo de previsão


SARIMA(0,0,0)(2,1,2)₁₂ teve melhor performance / menor BIC, RMSE, MAPE e Theil's U.


ETS teve a segunda melhor performance / terceiro menor BIC e segundo menor RMSE, MAPE e Theil's U. Registre-se que essa modelagem não passou no teste Ljung-Box de distribuição independente dos resíduos.

TSLM teve a terceira melhor performance / segundo menor BIC e terceiro menor RMSE, MAPE e Theil's U. Registre-se que essa modelagem não passou no teste Ljung-Box de distribuição independente dos resíduos.


8) Previsão


a) SARIMA(0,0,0)(2,1,2)₁₂ - modelo com melhor performance






b) ETS - modelo com segunda melhor performance






c) TSLM - modelo com terceira melhor performance



Forecasts from Linear regression model



9) Random Forest

```
##
## Call:
## randomForest(formula = rf_train ~ ., data = xregrf_train, importance = TRUE)
##           Type of random forest: regression
##           Number of trees: 500
## No. of variables tried at each split: 1
##
##           Mean of squared residuals: 1070.6
##           % Var explained: 97.31
##
##           ME      RMSE      MAE      MPE      MAPE      ACF1  Theil's U
## Test set  5.63353 37.48495 30.90604 -0.5944467 9.40789 -0.04236481 0.08040501
```

ANÁLISE:

Random Forest obteve menor RMSE, MAPE e Theil's U que os demais modelos - exceto o SARIMA(0,0,0)(2,1,2)12 e o ETS.

Portanto, pode-se considerar que Random Forest atingiu a terceira melhor performance entre as modelagens aqui consideradas.

10) Apêndice (código R)

```
rm(list=ls())
```

```
graphics.off()
```

```
library(urca)
```

```
library(forecast)
```

```
library(astsa)
```

```
library(tseries)
```

```
library(TSstudio)
```

```
library(randomForest)
```

```
df <- read.csv("C:/Users/mvrgu/OneDrive/Documentos/Scanned Documents/Mestrado/Estatística  
Econômica Aplicada/data_MarcusGuerra.csv", header = T, sep = ",", dec = ".")
```

```
plot(df[,1], df[,2], type = "l", col = "black", lty=1, main="Série Original", xlab="Observações",  
ylab="Valores", cex.main=1, cex.lab=1, font.main=1, font.lab=1)
```

```
acf2(df[,2], max.lag=60, main="Correlogramas da Série Original", cex.main=1, cex.lab=1, font.main=1,  
font.lab=1)
```

```
df1 <- ts(df, frequency=12)
```

```
dfcomponents1 <- stl(df1[,2], t.window=13, s.window="periodic", robust=TRUE)
```

```
plot(dfcomponents1, main="Decomposição da Série Original", cex.main=1, cex.lab=1, font.main=1,  
font.lab=1)
```

```
df.first_diff <- diff(df[,2])
```

```
plot(df.first_diff, type = "l", col = "black", lty=1, main="Primeira Diferença da Série Original",  
xlab="Observações", ylab="Valores", cex.main=1, cex.lab=1, font.main=1, font.lab=1)
```

```
acf2(df.first_diff, max.lag=60, main="Correlogramas da Primeira Diferença da Série Original", cex.main=1,  
cex.lab=1, font.main=1, font.lab=1)
```

```
df1.first_diff <- diff(df1[,2])
```

```

dfcomponents2 <- stl(df1.first_diff, t.window=13, s.window="periodic", robust=TRUE)

plot(dfcomponents2, main="Decomposição da Primeira Diferença da Série Original", cex.main=1, cex.lab=1,
font.main=1, font.lab=1)

df.first_sdiff12 <- diff(df[,2],12)

plot(df.first_sdiff12, type = "l", col = "black", lty=1, main="Primeira Diferença Sazonal de Ordem
12 da Série Original", xlab="Observações", ylab="Valores", cex.main=1, cex.lab=1, font.main=1, font.lab=1)

acf2(df.first_sdiff12, max.lag=60, main="Correlogramas da Primeira Diferença Sazonal de Ordem 12 da
Série Original", cex.main=1, cex.lab=1, font.main=1, font.lab=1)

df1.first_sdiff12 <- diff(df1[,2],12)

dfcomponents3 <- stl(df1.first_sdiff12, t.window=13, s.window="periodic", robust=TRUE)

plot(dfcomponents3, main="Decomposição da Primeira Diferença Sazonal de Ordem 12 da Série Original",
cex.main=1, cex.lab=1, font.main=1, font.lab=1)

test.adf <- ur.df(df1.first_sdiff12, lags = 60, type = "drift", selectlags = "BIC")

summary(test.adf)

test.kpss <- ur.kpss(df1.first_sdiff12, type = "mu", use.lag=NULL)

summary(test.kpss)

kpss.test(df1.first_sdiff12)

(fit1 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(4, 1, 4)))

(fit2 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(4, 1, 3)))

(fit3 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(4, 1, 2)))

(fit4 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(4, 1, 1)))

(fit5 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(4, 1, 0)))

(fit6 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(3, 1, 4)))

(fit7 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(3, 1, 3)))

```

```

(fit8 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(3, 1, 2)))

(fit9 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(3, 1, 1)))

(fit10 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(3, 1, 0)))

(fit11 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(2, 1, 4)))

(fit12 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(2, 1, 3)))

(fit13 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(2, 1, 2)))

(fit14 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(2, 1, 1)))

(fit15 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(2, 1, 0)))

(fit16 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(1, 1, 4)))

(fit17 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(1, 1, 3)))

(fit18 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(1, 1, 2)))

(fit19 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(1, 1, 1)))

(fit20 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(1, 1, 0)))

(fit21 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(0, 1, 4)))

(fit22 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(0, 1, 3)))

(fit23 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(0, 1, 2)))

(fit24 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(0, 1, 1)))

(fit25 <- Arima(df1[,2], order = c(0, 0, 0), seasonal = c(0, 1, 0)))

fit26 <- auto.arima(df1[,2], p=0, d=0, max.q=0, max.P=4, D=1, max.Q=4, stepwise = FALSE, max.order
= 8, approximation = FALSE, test = "adf", ic = "bic", trace = TRUE)

summary(fit26)

autoplot(fit13)

```



```

acf2(resid(fit13), max.lag=60, cex.main=1, cex.lab=1, font.main=1, font.lab=1)

checkresiduals(fit13, test="LB")

jarque.bera.test(residuals(fit13))

df_split <- ts_split(df1[,2], sample.out = 24)

df_train <- df_splittrain  $df_{test} < -df_{splittest}$ 

m1 <- (fit_train <- Arima(df_train, order = c(0, 0, 0), seasonal = c(2, 1, 2)))

summary(m1)

BIC(m1)

forecast.m1 <- forecast(m1, h=24)

accuracy(forecast(m1, h=24), df_test)

checkresiduals(m1, test="LB")

acf2(resid(m1), max.lag=60)

jarque.bera.test(residuals(m1))

m2 <- ets(df_train)

summary(m2)

BIC(m2)

forecast.m2 <- forecast(m2, h=24)

accuracy(forecast(m2, h=24), df_test)

checkresiduals(m2, test="LB")

acf2(resid(m2), max.lag=60)

m3 <- tslm(df_train ~ season + trend)

```

```

summary(m3)

BIC(m3)

forecast.m3 <- forecast(m3, h=24)

accuracy(forecast(m3, h=24), df_test)

checkresiduals(m3, test="LB")

acf2(resid(m3), max.lag=60)

m4 <- holt(df_train, h = 24)

summary(m4)

forecast.m4 <- forecast(m4, h=24)

accuracy(forecast(m4, h=24), df_test)

checkresiduals(m4, test="LB")

acf2(resid(m4), max.lag=60)

m5 <- holt(df_train, damped = TRUE, h = 24)

summary(m5)

forecast.m5 <- forecast(m5, h=24)

accuracy(forecast(m5, h=24), df_test)

checkresiduals(m5, test="LB")

acf2(resid(m5), max.lag=60)

m6 <- ses(df_train, h = 24)

summary(m6)

forecast.m6 <- forecast(m6, h=24)

```

```

accuracy(forecast(m6, h=24), df_test)

checkresiduals(m6, test="LB")

acf2(resid(m6), max.lag=60)

m7 <- naive(df_train, h = 24)

summary(m7)

forecast.m7 <- forecast(m7, h=24)

accuracy(forecast(m7, h=24), df_test)

checkresiduals(m7, test="LB")

acf2(resid(m7), max.lag=60)

autoplot(forecast(m1, h = 24), include = 500) + autolayer(df_test)

autoplot(forecast(m1, h = 24), include = 50) + autolayer(df_test)

autoplot(forecast(m2, h = 24), include = 500) + autolayer(df_test)

autoplot(forecast(m2, h = 24), include = 50) + autolayer(df_test)

autoplot(forecast(m3, h = 24), include = 500) + autolayer(df_test)

autoplot(forecast(m3, h = 24), include = 50) + autolayer(df_test)

dfrf <- df %>% timetk::tk_augment_lags(x, .lags = 1:12)

dfrf2 <- dfrf[-c(1:12),]

rfts <- ts(dfrf2x, frequency = 12) xreg_rfts <- -ts(dfrf2x_lag12, frequency = 12)

rf_split <- ts_split(rfts, sample.out = 24)

rf_train <- rf_splittrain rf_test <- -rf_splittest

xreg_rf_split <- ts_split(xreg_rfts, sample.out = 24)

```

```
xregf_train <- xregf_splittrain xregf_test < -xregf_test

Random_Forest <- randomForest(rf_train ~ ., data = xregf_train, importance = TRUE)

print(Random_Forest)

pred.rf <- predict(Random_Forest, newdata = xregf_test, n.ahead = 24)

accuracy(pred.rf,rf_test)
```